



上海交通大学  
SHANGHAI JIAO TONG UNIVERSITY



# 因果关系识别

叶南阳




## 第一节 前门调整



- 上节课中，我们了解到后门调整可以识别因果效应：
- 后门调整：假设变量集合  $W$  满足后门准则 —— 固定  $W$  作为条件可以阻塞  $T$  和  $Y$  之间的所有后门路径； $W$  不包含  $T$  的所有子孙结点，那么  $T$  对  $Y$  的因果效应可由以下公式计算：


$$P(y|do(t)) = \sum_w P(y|t, w)P(w)$$

- 然而对于含有未观测变量的情况，我们无法block所有后门路径，那么有没有办法可以不满足后门准则也能识别因果效应？




$W$ 无法被观察到，如何识别因果效应


- 例如，右侧因果图中，含有未观测变量  $W$ ，我们不能阻塞通过  $W$  的后门路径和沿此路径的混杂关联。
- 事实证明，使用前门调整可以识别右图的因果效应。我们首先来介绍前门准则和前门调整；然后在第二节介绍 do-calculus，考虑更一般的情况；最后在第三节介绍因果图的可识别性。



- 通过引入中间变量  $M$ ，只关注经过  $M$  的因果关联 (沿  $T$ - $M$ - $Y$  这条有向路径流动的关联)。




- 使用三个步骤来识别  $T$  对  $Y$  的因果效应:
- (1) 识别  $T$  对  $M$  的因果效应;
- (2) 识别  $M$  对  $Y$  的因果效应;
- (3) 结合(1)和(2), 识别  $T$  对  $Y$  的因果效应。




- (1) 识别  $T$  对  $M$  的因果效应  $P(m|do(t))$ :
- 因为  $Y$  是  $W$ - $M$  的对撞机 (collider), 所以  $Y$  阻塞  $T$ - $M$  的后门路径。即经过  $T$ - $M$  的唯一关联是因果关联。因此根据后门调整可得:

$$P(m|do(t)) = P(m|t)$$



- (2) 识别  $M$  对  $Y$  的因果效应  $P(y|do(m))$ :
- 因为  $T$  阻塞了  $M \leftarrow T \leftarrow W \rightarrow Y$  的后门路径, 运用后门调整, 得到:


$$P(y|do(m)) = \sum_t P(y | m, t)P(t)$$



- (3) 结合(1)和(2), 识别  $T$  对  $Y$  的因果效应  $P(y | do(t))$ :
- 由(1), 我们得到了  $T$  对  $M$  的影响, 由(2), 我们得到  $M$  对  $Y$  的影响, 结合两者, 我们可以得到  $T$  对  $Y$  的影响:

$$P(y | do(t)) = \sum_m P(m | do(t))P(y | do(m))$$

- 其中, 右边第一个因子对应将  $T$  设置为  $t$  时,  $M$  的结果。第二个因子对应将  $M$  设置为  $m$  下,  $Y$  的结果。这里  $P(M | do(t))$  是干预分布, 对随机变量分布  $P(M | do(t))$  的所有可能的取值  $P(M=m | do(t))$  求和。







- 前门准则:

我们说变量集  $M$  关于  $T$  和  $Y$  满足前门准则, 若满足以下条件:

- 1.  $M$  完全中介了  $T$  和  $Y$ , 即所有从  $T$  到  $Y$  的因果路径都经过  $M$ ;
- 2. 从  $T$  到  $M$  没有未被阻断的后门路径;
- 3. 所有从  $M$  到  $Y$  的后门路径被  $T$  阻断。

- 定理: 前门调整 (Frontdoor Adjustment)

如果  $(T, M, Y)$  满足前门准则, 并且满足非负性假设, 则:

$$P(y \mid do(t)) = \sum_m P(m \mid t) \sum_{t'} P(y \mid m, t') P(t')$$



- 我们基于截断式因子分析和贝叶斯网络给出前门调整定理的 证明，证明：

$$P(w, t, m, y) = P(w)P(t | w)P(m | t)P(y | w, m) \quad (\text{贝叶斯网络})$$

$$P(w, m, y | do(t)) = P(w)P(m | t)P(y | w, m) \quad (\text{截断式因子分解, 移除 } T)$$

$$\sum_m \sum_w P(w, m, y | do(t)) = \sum_m \sum_w P(w)P(m | t)P(y | w, m) \quad (\text{对 } m \text{ 和 } w \text{ 求和})$$

$$P(y | do(t)) = \sum_m P(m | t) \sum_w P(y | w, m)P(w)$$

我们的目标是把未观测变量  $w$  消去，只留下  $t, m, y$ ，在上式中，如果能将  $P(w)$  转化为  $P(w|m)$ ，就能刚好消去  $w$ ，由  $w$  与  $m$  关于  $T$  条件独立（Chain结构）可得  $P(w|t) = P(w|m, t)$ ，于是上式可化为：

$$\begin{aligned} P(y | do(t)) &= \sum_m P(m | t) \sum_w P(y | w, m)P(w) \\ &= \sum_m P(m | t) \sum_w P(y | w, m) \sum_{t'} P(w | t')P(t') \\ &= \sum_m P(m | t) \sum_w P(y | w, m) \sum_{t'} P(w | t', m)P(t') \\ &= \sum_m P(m | t) \sum_{t'} P(t') \sum_w P(y | w, m)P(w | t', m) \end{aligned}$$



- 为了结合  $P(y | w, m)$  和  $P(w | t', m)$ , 还需要对  $P(y | w, m)$  引入条件  $t'$

$$P(y | w, m) = P(y | w, m, t') \quad (\text{因为 } W \text{ 和 } M \text{ 已经 d-分离 } T \text{ 和 } Y)$$

- 因此,

$$\begin{aligned} P(y | do(t)) &= \sum_m P(m | t) \sum_{t'} P(t') \sum_w P(y | w, m) P(w | t', m) \\ &= \sum_m P(m | t) \sum_{t'} P(t') \sum_w P(y | w, t', m) P(w | t', m) \\ &= \sum_m P(m | t) \sum_{t'} P(t') \sum_w P(y, w | t', m) \\ &= \sum_m P(m | t) \sum_{t'} P(t') P(y | t', m) \end{aligned}$$

- 将 (1) 和 (2) 的结论  $P(m|do(t)) = P(m|t)$  和  $P(y | do(m)) = \sum_t P(y | m, t) P(t)$  代入上式得到:


$$P(y | do(t)) = \sum_m P(m | t) \sum_{t'} P(y | m, t') P(t') = \sum_m P(y|do(m)) P(m|do(t))$$

证毕。

- 经典的吸烟的因果效应悖论：

- 早在20世纪50年代，焦油沉积的形成就被怀疑是肺癌发展的一个可能的中间阶段。

- 假设研究人员可以测量吸烟者肺部的焦油沉积量，吸烟基因是吸烟行为和肺癌的混杂因子。




- 上图包含了两个非常重要的假设：

- (1) **吸烟基因对焦油沉积物的形成没有影响，焦油沉积只与香烟烟雾的物理作用有关。**这一假设以“吸烟基因”和“焦油沉积”之间没有箭头来表明；不过它并不能排除与“吸烟基因”无关的其他随机因素对“焦油沉积”的影响。
- (2) **只有通过焦油沉积的积累，“吸烟”才会导致“癌症”。**因此，我们假设从“吸烟”到“癌症”之间没有直接箭头，也没有其他间接路径。

		$P(x, z)$	$P(Y = 1   x, z)$
		Group Size	% of Cancer Cases
Group Type		(% of Population)	in Group
$X = 0, Z = 0$	Nonsmokers, No tar	47.5	10
$X = 1, Z = 0$	Smokers, No tar	2.5	90
$X = 0, Z = 1$	Nonsmokers, Tar	2.5	5
$X = 1, Z = 1$	Smokers, Tar	47.5	85

- 从数据中来看，似乎吸烟对肺癌有显著影响，但烟草公司会从不同的角度争辩，从而给出不同的答案——若只看非吸烟者，体内有焦油的人群患癌率从10%降到了5%；若只看吸烟者，体内有焦油的人群患癌率从90%降到了85%，以此来争辩焦油有防护作用。






		$P(x, z)$ Group Size (% of Population)	$P(Y = 1   x, z)$ % of Cancer Cases in Group
Group Type			
$X = 0, Z = 0$	Nonsmokers, No tar	47.5	10
$X = 1, Z = 0$	Smokers, No tar	2.5	90
$X = 0, Z = 1$	Nonsmokers, Tar	2.5	5
$X = 1, Z = 1$	Smokers, Tar	47.5	85

运用前门调整  $P(y | do(x)) = \sum_z P(z | x) \sum_{x'} P(y | z, x') P(x')$  :

计算 $P(\text{癌症} | do(\text{吸烟}))$  和  $P(\text{癌症} | do(\text{不吸烟}))$





$$P(y = 1 \mid do(x = 0))$$

$$= \sum_z P(z \mid x = 0) \sum_{x'} P(y = 1 \mid z, x') P(x')$$

$$= P(z = 0 \mid x = 0) \sum_{x'} P(y = 1 \mid z = 0, x') P(x') + P(z = 1 \mid x = 0) \sum_{x'} P(y = 1 \mid z = 1, x') P(x')$$


$$= P(z = 0 \mid x = 0) [P(y = 1 \mid z = 0, x' = 0) P(x' = 0) + P(y = 1 \mid z = 0, x' = 1) P(x' = 1)] + \\ P(z = 1 \mid x = 0) [P(y = 1 \mid z = 1, x' = 0) P(x' = 0) + P(y = 1 \mid z = 1, x' = 1) P(x' = 1)]$$

$$= 0.95 * (0.10 * 0.5 + 0.9 * 0.5) + 0.05 * (0.05 * 0.5 + 0.85 * 0.5) = 0.4975$$

同理：  $P(y = 1 \mid do(x = 1)) = 0.4525$

$$P(Y = 1|do(X = 0)) = 0.4975, P(Y = 1|do(X = 1)) = 0.4525$$

这个结论基于前面提到的两个假设时成立，**如果认为吸烟基因对焦油沉积有因果效应，则前门调整失效。**




因果图的正确性，决定了因果推理的正确性





考虑右侧的因果图：

- (a) 列出所有满足后门准则以确定 $X$ 对 $Y$ 的因果关系的变量集。
- (b) 列出所有满足确定 $X$ 对 $Y$ 的因果影响后门准则的最小变量集，(即从集合中删除其中任何一组变量，它将不再满足准则)。






(a) 列出所有满足后门准则以确定X对Y的因果关系的变量集。

1. *Sets of 2 nodes:*  $\{Z, A\}, \{Z, B\}, \{Z, C\}, \{Z, D\}$
2. *Sets of 3 nodes:*  $\{Z, A, B\}, \{Z, A, C\}, \{Z, A, D\}, \{Z, B, C\}, \{Z, B, D\}, \{Z, C, D\}$
3. *Sets of 4 nodes:*  $\{Z, A, B, C\}, \{Z, A, B, D\}, \{Z, A, C, D\}, \{Z, B, C, D\}$
4. *Sets of 5 nodes:*  $\{Z, A, B, C, D\}$

(b) 列出所有满足确定 X 对 Y 的因果影响后门准则的最小变量集,  
(即从集合中删除其中任何一组变量, 它将不再满足准则)。

$\{Z, A\}, \{Z, B\}, \{Z, C\}, \{Z, D\}$






- 后门调整公式和后门标准就像硬币的正反面。后门标准告诉我们哪些变量集可以用来去除数据中的混杂。
- 遗憾的是，如果我们因缺乏必要的数据而无法阻断某条后门路径，后门调整公式就会完全失灵。然后通过引入中间变量，使用前门调整，只关注经过中间变量的因果关联，来完成因果推断。



## 第二节 do-calculus



- 上节中，我们了解了通过前门调整识别因果效应。那么当  $T$  到  $Y$  之间既不满足前门准则，也不满足后门准则的时候，怎么识别因果效应呢？
- 如右图，前后门准则都无法使用。
- 因为  $W1$  和  $W2$  都是无法观测的，无论使用前门准则还是后门准则， $T$  对于  $Y$  的因果效应总是无法正确估计。对于这种情况，我们可以使用unconfounded children criterion或者 do-calculus 来正确估计。本节首先介绍 do-calculus 理论。





- 事实上，前门调整公式和后门调整公式的最终目标是根据  $P(Y | X, A, B, Z, \dots)$  此类不涉及do算子的数据估算干预的效果，即  $P(Y | \text{do}(X))$ 。
- 如果我们成功消除了计算过程中的do概率，就可以利用观测数据来估计因果效应，这样一来，我们就从因果关系之梯的第一层级（相关性估计）踏上了第二层级（因果性估计）。



- 在介绍 do-算子 之前，我们先给出符号说明：
- $G_{\bar{X}}$ ：移除  $G$  中所有指向  $X$  的边，即  $X$  没有双亲结点；
- $G_{\underline{X}}$ ：  $G$  中所有被  $X$  指向的边，即  $X$  没有孩子结点；
- $G_{\overline{Z(W)}}$ ：移除  $Z$  指向  $W$  的所有边，即  $Z$  不是  $W$  的双亲结点；
- $\perp\!\!\!\perp_G$ ： d分离



- do-calculus 三公理:

给定因果图 $G$ , 关联分布 $P$ , 不相交的随机变量  $Z, T, W, Y$ , 则有以下准则:

- (1) 增添或删除观察 (Ignoring observations)

$$P(y \mid do(t), z, w) = P(y \mid do(t), w) \quad \text{if} \quad Y \perp\!\!\!\perp_{G_{\overline{T}}} Z \mid T, W$$

- (2) 干预与观察交换 (Action / Observation exchange)

$$P(y \mid do(t), do(z), w) = P(y \mid do(t), z, w) \quad \text{if} \quad Y \perp\!\!\!\perp_{G_{\overline{T}Z}} Z \mid T, W$$

- (3) 增添或删除干预 (Ignoring actions)

$$P(y \mid do(t), do(z), w) = P(y \mid do(t), w) \quad \text{if} \quad Y \perp\!\!\!\perp_{G_{\overline{T}Z(w)}} Z \mid T, W$$





- do-calculus 三公理的直观解释：

## (1) 增添或删除观察 (Ignoring observations)

- 如果移除干预  $do(t)$ , 得到：

$$P(y | z, w) = P(y | w) \quad \text{if} \quad Y \perp\!\!\!\perp_G Z | W$$

- 上式正是 d-分离 (d-separation) 的定义, 即准则 (1) 是 d-分离 到干预分布的泛化。

## (2) 干预与观察交换 (Action / Observation exchange)

- 如果移除干预  $do(t)$ , 得到：

$$P(y | do(z), w) = P(y | z, w) \quad \text{if} \quad Y \perp\!\!\!\perp_{G_{\underline{Z}}} Z | W$$

- 上式是后门调整, 即准则 (2) 是后门调整到干预分布的泛化。



- do-calculus 三公理的直观解释：

### (3) 增添或删除干预 (Ignoring actions)

- 如果移除干预  $do(t)$ , 得到：

$$P(y \mid do(z), w) = P(y \mid w) \text{ if } Y \perp\!\!\!\perp_{G_{\overline{Z(W)}}} Z \mid W$$

- 观察条件  $Y \perp\!\!\!\perp_{G_{\overline{Z(W)}}} Z \mid W$ ,  $G_{\overline{Z(W)}}$  表示移除  $Z$  指向  $W$  的所有边。当  $Z$  没有指向  $W$  的边时, 给定  $W$ ,  $Y$  和  $Z$  是 d-分离的, 那么这种情况下干预  $do(z)$  对  $y$  没有影响 (Modularity)。



- do-calculus 三条基本准则的完备性：
- 是否可能存在不能用 do-calculus 准则来识别的可识别因果图？
- 答案是否定的，Shpitser和Pearl 等证明了 do-calculus 是完备的，即 do-calculus 的三个准则可以识别所有可识别的因果推断。
- do-calculus三条基本准则证明：  
参考文献： <https://arxiv.org/pdf/1305.5506.pdf>



- 上节我们基于截断式因子分析和贝叶斯网络给出前门调整的证明，本节我们基于do-calculus 的三个准则给出  $P(y | do(t)) = \sum_m P(m | t) \sum_{t'} P(y | m, t') P(t')$  的证明，并结合吸烟与肺癌的例子，以此解释三公理：

$$P(y | do(t)) = \sum_m P(y | do(t), m) P(m | do(t)) \quad (\text{全概率公式})$$

$$= \sum_m P(y | do(t), m) P(m | t) \quad (\text{公理 (2) 干预观察交换})$$



$$= \sum_m P(y | do(t), do(m)) P(m | t) \quad (\text{公理 (2) 干预观察交换})$$

$$= \sum_m P(y | do(m)) P(m | t) \quad (\text{公理 (3) 删除干预})$$

$$= \sum_m P(m | t) \sum_{t'} P(y | do(m), t') P(t' | do(m)) \quad (\text{全概率公式})$$


$$= \sum_m P(m | t) \sum_{t'} P(y | m, t') P(t' | do(m)) \quad (\text{公理 (2) 干预观察交换})$$

$$= \sum_m P(m | t) \sum_{t'} P(y | m, t') P(t') \quad (\text{公理 (3) 删除干预})$$






- 考虑如下因果图，假设只有  $X$ ,  $Y$  和 另一个随机变量是可观测的，确定该随机变量，使得  $X$  对  $Y$  的因果效应是可识别的，并写出  $X$  对  $Y$  的因果效应。





- 考虑如下因果图，假设只有  $X$ ,  $Y$  和 另一个随机变量是可观测的，确定该随机变量，使得  $X$  对  $Y$  的因果效应是可识别的，并写出  $X$  对  $Y$  的因果效应。



- $W$  , 满足前门准则,  $P(y \mid do(x)) = \sum_w P(w \mid x) \sum_{x'} P(y \mid x', w) P(x')$



- 药店有两种药：一种定价 1 美元，另一种定价 10 美元。10美元一瓶的日期新鲜，而1美元一瓶的已经放置了3 年。”但数据显示，那些买便宜药的康复率要高得多。现对这两种药进行药性测试，测试结果表明 95%的陈年药品和 5%的新鲜药品失去了有效成分，但使用陈年药品的人群的康复率远高于使用新鲜药品人群的康复率。”
- 为了分析药品与康复的因果效应，现在提供一些调研数据。数据包括每位顾客购买的药的类型(陈年的或新鲜的)，药品中有效成分的浓度(高或低)，以及顾客是否从疾病中恢复。



- 数据完全证实了陈年药品康复率远高于新鲜药品。

	Cheap	Expensive	All Subjects
	400	400	800
	Low   High	Low   High	Low   High
	380   20	20   380	400   400
Recovery	323   18	1   38	324   56
Not Recovery	57   2	19   324	76   344

- 基于两个非常合理的假设，请你分析新鲜药品真的会给普通病人提供更大的康复机会吗？
  - (i) 顾客对所购买药品的化学含量(高或低)没有任何信息；他们的选择只受价格和日期的影响。
  - (ii) 药物对任何特定个体的作用只取决于其化学成分，而不取决于药品日期。






	Cheap	Expensive	All Subjects
	400	400	800
	Low   High	Low   High	Low   High
	380   20	20   380	400   400
Recovery	323   18	1   38	324   56
Not Recovery	57   2	19   324	76   344

- 具体考虑两个问题：
- (a) 确定问题的相关变量，并在因果图中描述这种情况。
- (b) 基于假设 (i) 和 (ii) 以及给出的数据，确定选择新鲜药物和陈年药物对康复率的因果效应。



(a)  $X, Y, Z$  分别表示药物是否新鲜，药物化学成分浓度，是否恢复。因果图为：



(b) 比较两种药物的因果效应。令  $y_1$  表示恢复， $x_1$  表示选择新鲜药品， $z_1$  表示化学成分高。应用前门准则，类似吸烟与肺癌实例的分析，计算  $X$  对  $Y$  的因果效应，由计算结果，新鲜药品的恢复效果好于陈年药品。



$$\begin{aligned}P(y_1|do(x_1)) &= \sum_z P(z|x_1) \sum_{x'} P(y_1|x', z) P(x') \\&= P(z_1|x_1)[P(y_1|x_1, z_1)P(x_1) + P(y_1|x_0, z_1)P(x_0)] \\&\quad + P(z_0|x_1)[P(y_1|x_1, z_0)P(x_1) + P(y_1|x_0, z_0)P(x_0)] \\&= 0.95 * (0.1 * 0.5 + 0.9 * 0.5) + 0.05 * (0.05 * 0.5 + 0.85 * 0.5) \\&= 0.4975\end{aligned}$$

$$\begin{aligned}P(y_1|do(x_0)) &= \sum_z P(z|x_0) \sum_{x'} P(y_1|x', z) P(x') \\&= P(z_1|x_0)[P(y_1|x_1, z_1)P(x_1) + P(y_1|x_0, z_1)P(x_0)] \\&\quad + P(z_0|x_0)[P(y_1|x_1, z_0)P(x_1) + P(y_1|x_0, z_0)P(x_0)] \\&= 0.05 * (0.1 * 0.5 + 0.9 * 0.5) + 0.95 * (0.05 * 0.5 + 0.85 * 0.5) \\&= 0.4525\end{aligned}$$

$$\begin{aligned}ACE &= P(y_1|do(x_1)) - P(y_1|do(x_0)) \\&= 0.045 > 0\end{aligned}$$



- 药物选择和恢复之间**未被观察到的混杂因素**可能会造成便宜的药物更有效的错觉。比如，**更节俭**的顾客同时也有**更健康的饮食习惯**。
- 为了消除这种错觉，我们必须评估ACE。首先，我们可以计算药物的有效成分对恢复的因果影响。设  $p$  ( $p'$ )表示随机选择的人服用活性成分含量高(低)的药物后的恢复概率，即：

$$p = P(Y = \text{recover} | do(Z = \text{high}))$$

$$p' = P(Y = \text{recover} | do(Z = \text{low}))$$

- 我们已通过计算得到了成分的因果效应，可以进行进一步分析：如果选择新鲜药品，则有5%的机会得到有效成分高的药，恢复率为  $p$ ，有95%的机会得到有效成分低的药，恢复率为  $p'$ 。因此，选择陈年药品的平均恢复率是  $0.05p + 0.95p'$ 。相应新鲜药品的平均恢复率是  $0.95p + 0.05p'$ 。因此，两种选择之间的差别为： $0.05(p - p') + 0.95(p' - p) = 0.9(p' - p)$ 。如果  $p' < p$ ，则新鲜药品更具优势。